



CHALLENGE IA I AUDITORIA **ESTIMACIÓ DEL DETERIORAMENT DE LES EXISTÈNCIES**

Document Resum

Descripció general del model,
principals fites i conclusions

Grup: GIA UPC

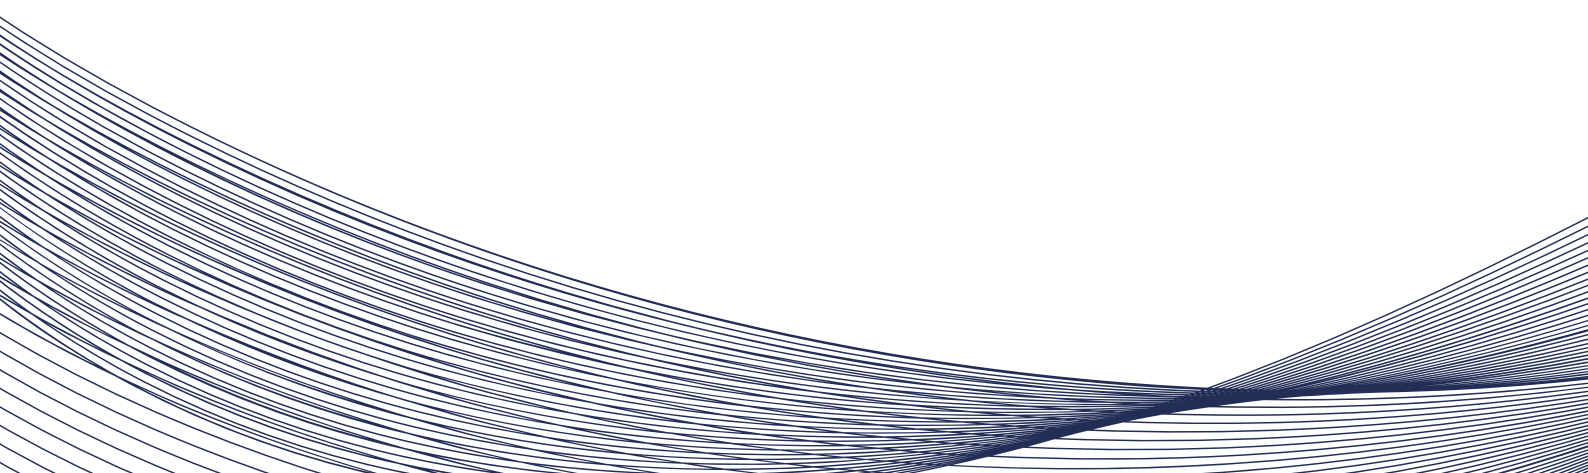
Roger Baiges Trilla
Pau Hidalgo Pujol
Cai Selvas Sala



ÍNDEX

CONTINGUT DE L'INFORME

Introducció	1
Challenge i Objectius	1
Model	2
• Dades	3
• Càlculs i IA	4
• Combinació	5
Resultats	6
Propostes addicionals	7
Conclusions	8



INTRODUCCIÓ

El devaluament del valor de les existències és un procés complex d'auditoria que combina l'anàlisi de dades amb criteris d'un expert.

Per la gran quantitat de dades de les quals disposen les empreses actualment, és de gran utilitat proporcionar models d'intel·ligència artificial (IA) capaços d'agilitzar aquest procés i aportar valor.

CHALLENGE I OBJECTIUS

DETERIORAMENT D'EXISTÈNCIES

El deteriorament d'existències consisteix a efectuar les correccions necessàries quan el valor net realitzable esdevé menor al preu d'adquisició. Aquest valor (VNR), de forma resumida és el valor total que es pot obtenir venent aquest actiu, menys els costos que pot comportar vendre'l (és diferent del valor de mercat). Tot i això, cal tenir en compte altres aspectes del producte, com l'obsolescència (inventari que passa molt temps emmagatzemat sense vendre's), que provoca que vagi disminuint el valor comercial, i altres efectes. A més, aquestes pèrdues es comptabilitzen, i per tant hauran de ser acreditades i documentades correctament.

OBJECTIUS

L'objectiu és implementar la Intel·ligència Artificial en aquest procés per tal de millorar la seva eficiència i eficàcia. A més, determinades tècniques poden servir per a poder acreditar i entendre per quins motius es comptabilitza aquest deteriorament.

Amb la implementació del model que es presentarà a continuació, es busca realitzar una estimació d'aquest deteriorament basada en diferents criteris que utilitzen Intel·ligència Artificial per obtenir el màxim d'informació de les dades. A més, s'interpretaran aquests valors per tal d'indicar quines són les característiques rellevants de cada material que influeixen en aquest deteriorament. Addicionalment, es proposaran altres possibles aplicacions de IA que permeten complementar aquest model o dur a terme estimacions diferents. També es busca que sigui el més flexible possible per tal de poder adaptar-se a situacions diferents i poder ser personalitzat per un auditor segons la naturalesa de cada problema (sense necessitat de coneixements en IA ni en programació).



MODEL


El model creat combina diferents tècniques, cada una més avançada que l'anterior, per arribar a aquesta estimació. Per arribar a tal punt, cal seguir diversos passos de tractament de dades i aplicació de models d'IA, que un expert podria combinar i adaptar a qualsevol altra base de dades amb la mateixa informació o similar.

DADES

En un tractament de dades inicial, s'han unificat els fitxers d'Excel en un de sol per facilitar el tractament de les dades. A més, s'han creat noves variables simples (operacions entre altres variables, que es podrien fer en un excel directament):

- Dies des de l'última sortida
- Dies des de l'última entrada
- Diferència entre entrada i sortida (en dies)
- Preu de venda unitari el 2022
- Variació en el preu de venda unitari (entre 2022 i 2023)
- Variació en les vendes (entre 2022 i 2023)
- Variació en les unitats venudes (entre 2022 i 2023)
- Proporcions de totes aquestes variacions mencionades

Addicionalment, es creen dades de vendes mensuals, que serviran per a alguns models més endavant. Aquestes són creades de manera artificial, però complint amb les dades de les quals disposàvem (mes d'última venda, vendes totals anuals...). A més, hi ha pesos (paràmetres personalitzables) mensuals adaptables a les tendències dels productes (més vendes a l'estiu, per exemple). En cas de disposar de dades mensuals reals, es podrien usar i milloraria encara més el rendiment del model.



Exemple de dades mensuals generades per un producte

id_2022	preu_venda_unitari_2022	unitats_2023	vendes_2023	preu_venda_unitari_2023	variacio_unitats_2022_2023	proporcio_variacio_unitats_2022_2023	variacio_preu_venda_unitari_2022_2023
4892,49	0,053895425	885500	58951,87	0,06657467	-133000	-0,130584192	20,162612385
6825,62	0,089929117	27600	2127,68	0,077089855	-48300	-0,636363636	0,141125495
10307,84	0,113470407	340000	34522,45	0,101536618	-544000	-0,615384615	0,151284789
5179,48	0,223089977	15600	3770,68	0,241710256	-7617	-0,328078563	0,154585
26188,5	0,073357143	1023000	74195,5	0,07252737	666000	1,865546218	0,114577742
10998,44	0,116658	1533600	156152,48	0,101820866	1353600	7,52	0,141282927
0	0	0	0	0	0	0	0,032251053
4814,65	0,162612385	152600	26612,66	0,174394889	0	0	0,048810917
10467,24	0,141125495	741400	109717,26	0,147986593	29500	0,041438404	0,02943807
56967,8	0,151284789	308000	51353,82	0,166733182	-68560	-0,182069259	0,0322179
11535,34	0,154585	85000	13904,98	0,163588	-119000	-0,583333333	0,029613111
11966,72	0,114577742	4128000	467805,12	0,113324884	-1824000	-0,306451613	0,029613111
11706,72	0,141282927	332000	49449,76	0,14894506	36800	0,124661247	0,0343
14119,44	0,032251053	648000	22376,88	0,034532222	-720000	-0,526315789	0,031455
72747,79	0,048810917	900000	41220,72	0,0458008	-590400	-0,396135266	0,027401142
11937,25	0,02943807	1618200	47125,84	0,029122383	873000	1,171497585	0,028516204
16111,13	0,0322179	2016000	61591,68	0,030551429	-36000	-0,01754386	0,034258571
15593,36	0,044432917	108000	4217,4	0,03905	-468000	-0,8125	0,029070035
13986,62	0,029613111	864000	25669,8	0,029710417	54000	0,066666667	0,029985826
1234,8	0,0343	72000	2934	0,04075	36000	1	0,033882207
11706,64	0,031455	180000	4838,4	0,02688	-828000	-0,821428571	0,033882207
10801,53	0,027401142	252000	7451,64	0,02957	-142200	-0,360730594	0,033882207
11558,25	0,028516204	149370	4411,28	0,02953257	-606630	-0,802420635	0,033882207
17266,32	0,034258571	1135800	35866,95	0,031578579	631800	1,253571429	0,033882207
18682,89	0,029070035	14090400	401719,7	0,02851017	4159800	0,418887076	0,033882207
15834,16	0,029985826	9718200	296880,1	0,030548877	3520800	0,568109207	0,033882207
135393,3	0,033882207	3600000	117084,96	0,0325236	-396000	-0,099099099	0,033882207

Per poder realitzar una estimació del deteriorament del valor, es calcula un valor de devaluació per cada material. El càlcul d'aquest valor s'ha implementat de tres formes diferents.

CÀLCUL FÓRMULA

El primer càlcul es basa simplement en una fórmula, imitant el comportament de fórmules financeres. Aquesta pondera la diferència d'unitats (proporcional al 2022), la variació en el preu de venda unitari, el ràtio d'unitats-stock i el logaritme (per evitar l'efecte de valors massa grans) de la inactivitat. Aquestes ponderacions poden ser ajustades per l'auditor (o en cas de disposar de dades etiquetades (és a dir, amb els deterioraments ja indicats), es podrien arribar a estimar aquestes proporcions usant una xarxa neuronal, per exemple).



CÀLCUL SÈRIE TEMPORAL

El segon càlcul es basa en un model de sèries temporals (com podria ser l'ARIMA, però millorat). Aquest utilitza les dades mensuals generades per intentar predir les vendes l'any vinent. En funció de la disminució de les vendes, es calcula un valor relacionat amb la devaluació. S'interpreta que aquesta disminució de vendes el següent any, és causada per factors que provoquen que el valor actual hagi de ser menor al contemplat en els comptes. Els models que es poden usar (i els que hem provat) són diversos: des de l'ARIMA (el més bàsic), a FEDformer (basat en transformers), o TimesNet, basats en xarxes neuronals i en teoria amb millors capacitats que l'ARIMA. A més, aquests últims permeten l'addició de variables extra de context per a la predicció de la sèrie temporal resultant en càlculs més precisos i realistes.

CÀLCUL XARXA NEURONAL

El tercer càlcul, i el més complex, utilitza una xarxa neuronal (amb arquitectura auto-encoder), per obtenir representacions de cada material amb menys dimensions (característiques) però capaces de ser més significants, ja que han de poder representar els patrons de les dades. Aquestes són comparades, usant distàncies relatives (similitud) amb un element de referència molt negatiu. Com a menys distància tinguin a aquest element més deteriorament tindrà el producte.

Aquest element de referència és un material inventat on el preu unitari entre el 2022 i el 2023, les vendes entre 2022 i 2023 i les unitats venudes entre 2022 i 2023 disminueixen un 10.000%, tarda 730 dies a vendre's, fa 365 que no se'n ven cap, té un stock molt elevat per les vendes i un cost molt més gran al valor de venda.




Arquitectura autoencoder

COMBINACIÓ

SUMA PONDERADA

Els tres càlculs utilitzen fórmules diferents per a intentar determinar el deteriorament. Hem interpretat que cada un té els seus avantatges i inconvenients, i que són capaços de detectar elements diferents. Per tant, hem optat per realitzar una suma ponderada dels tres càlculs per obtenir un valor final. Per defecte es dona una major ponderació al tercer càlcul per la seva gran capacitat de trobar patrons complexos, tot i que pot ser adaptada per l'auditor, en funció de la importància que vol donar a cada càlcul.




Càlculs usant els tres mètodes

PREDICCIÓ

Per realitzar la predicció usant aquest valor, es resta un llindar (per defecte la mitjana) i es divideix per una "tolerància" (tots dos són paràmetres que poden ser personalitzats per l'auditor). D'aquesta manera obtenim un percentatge de deteriorament (negatiu si n'hi ha, positiu si augmenta el valor).

El llindar és el que defineix si el canvi de valor serà positiu o negatiu, mentre que la tolerància modifica en quina quantitat es modifica el valor.

La predicció acaba sent sumar al preu unitari del 2023 el percentatge corresponent d'aquest mateix valor.



Suma dels valors

DEVALUACIÓ

Aquesta predicció ens retorna una espècie de valor "just" estimat pel model. La devaluació tindrà lloc en aquells productes on aquest valor predit sigui menor al cost contemplat a stock.


RESULTATS

Les prediccions del model depenen d'alguns paràmetres personalitzables que idealment haurien d'estar relacionats amb dades reals o ser ajustats per un auditor. Tot i això, amb els valors per defecte establerts, considerem que les prediccions són bastant bones.

Aquestes prediccions poden ser comparades amb les devaluacions que faci una empresa per mirar si es corresponen (i, per tant, per determinar si són raonables o incorrectes).

TRAÇABILITAT

Adicionalment, el model utilitza un Explainable Boosting Machine (EBM) per proporcionar interpretabilitat i traçabilitat d'aquests resultats, sent capaç d'indicar quines són les variables que provoquen aquest deteriorament. Aquest és un punt molt important en el camp de l'auditoria, ja que totes les rectificacions han d'estar degudament argumentades.




Traçabilitat de la devaluació del material 173301004 (es ven més el 2023 però hi ha molta diferència entre l'entrada i la sortida. S'observa com les variables dels dies des de la última entrada/sortida afecten de forma negativa

PROPOSTES ADDICIONALS

Altres propostes addicionals conceptuals, i alguns inclosos en aquest projecte, de com es podria aplicar la IA en aquest problema.

DETECCIO DE FRAU

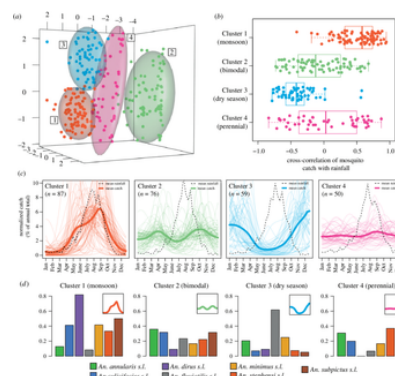
En lloc de calcular el deteriorament, es podria intentar predir aquells valors on l'empresa ha comès frau. Aquests models poden ser basats en aprenentatge supervisat (entrenant amb dades etiquetades), o bé en no supervisat com la detecció d'outliers.



Outliers detectats en les dades proporcionades. Aquest model està implementat també, com a extra.

CLASSIFICACIÓ

Es poden classificar els diferents productes en funció de la seva rellevància, o altres característiques, que permetin per exemple tenir grups on es devaluen. Una alternativa també seria usar clustering en sèries temporals, per intentar predir millor per exemple la "vida útil".



Exemple de clústering de sèries temporals

ALTRES FACTORS

Es poden usar altres tècniques de IA per a tenir en compte també altres factors, com el deteriorament físic dels taps (analitzant amb Visió per Computador), o dades de les tendències del mercat (o d'empreses competidores) o d'altres factors que puguin afectar.

EINES ADDICIONALS

Amb models de IA més avançats, es poden crear eines que puguin facilitar el treball. Un exemple seria usar un LLM (model de llenguatge) amb Retrieval Augmented Generation (RAG), que, basant-se en algunes regles predefinides per un expert, pot permetre obtenir les dades de manera molt senzilla tan sols interactuant amb un xat. Aquest s'ha implementat com a extra del nostre model (en un codi separat del model principal), per poder visualitzar els resultats de manera més fàcil i còmode.

You: hola que tal

ChatBot: Digues quina informació de la base de dades vols. Per exemple, dona'm el percentatge de devaluació del material 100022432

You: vull el valor just estimat pel material 135060910

ChatBot: El valor just estimat pel model és 0.1301862182852903

You: i el valor total de devaluació de la base?

ChatBot: Valor total devaluat: 261980.13071124017, en un total de 49 elements

You: quin index prediu l'autoencoder en 135062142?

ChatBot: El càlcul usant l'auto encoder (xarxa neuronal) és de 0.1088326592287745

Exemple (real) de RAG (xat interactiu) en la nostra base de dades. Al codi es pot realitzar un petit test de què podrien permetre aquests models

CONCLUSIONS

Amb el model presentat, es pot realitzar una estimació de la deterioració del valor de les existències, indicant també els motius d'aquesta estimació. Un auditor, probablement, no haurà de dur a terme aquesta estimació, sinó analitzar si és correcta la que realitza l'empresa, però es podria analitzar la diferència entre aquesta estimació i la de l'empresa, per exemple, facilitant i agilitzant la tasca de l'auditor.

En cas de disposar de dades etiquetades (amb el deteriorament ja indicat), el nostre model és capaç d'adaptar el tercer càlcul (el basat en una xarxa neuronal de tipus autoencoder) a les dades etiquetades per l'auditor, aprenent els patrons que hi troba i aplicant-los en les seves futures prediccions sobre el deteriorament d'existències. Tot i això, el model presentat és capaç de detectar patrons complexos i realitzar estimacions amb sentit, que a més poden acabar de ser refinades per un auditor i interpretades automàticament.

Adicionalment, al model de predicció, hem incorporat una forma d'afegir traçabilitat, ja que la considerem molt important en l'àmbit de l'auditoria, i també altres models addicionals que permeten veure més tecnologies que es podrien aplicar, com és el cas del mini-Xat (exemple de la pàgina anterior) que permet crear una interfície per interactuar amb les dades molt més fàcilment. Amb això, creiem que aportem un valor afegit als auditors que pot facilitar molt la realització de la seva tasca, que, al cap i a la fi, és l'objectiu del challenge.

Aquest és un document resum, pensat per tal de poder fer-se una idea del que hem creat de forma visual i entenedora. Les consideracions tècniques, i les explicacions més profundes es presentaran al document complet. A més, tot el codi del model es pot trobar al següent enllaç:

<https://github.com/caiselvass/challenge-auditoria>